



A DigiHum approach to HistSocLing of Estonian

Peeter Tinitis

25.07.2019

National Library of Latvia

BSSD2019




A case study in DH

- Project:
 - What mechanisms are responsible for spelling standardization at the end of 19th century Estonian?
- Data sources:
 - Anything relevant
- Timeline:
 - PhD dissertation

Some context

➤ Language change: intentional or not



Müller (1861), Saussure (1916), Lass (1999):
„Intentional language change is peripheral to language“



Jespersen (1925), Ferguson (1989), Thomason (2007)
„Intentional language change is quite central to language phenomenon“



- Language institutions and written norms have become normal for us.



Members of Académie Française (2019)

Languages without these grammars


- Sociolinguistic research has shown that this is not always the case
- Of ~7,000 languages, ~3,000 still are not written



Even much writing is without standards

Shakespere,
Shackspeare,
Shakespear,
Shakspere,
Shaxspere,
Shaxper,
Shakspeare,
Shackespeare,
Shackspere,
Shackespere

- E.g. English became standardised from ~18c onwards



Samuel Johnson (1750):
Dictionary of English Language

- Shakespeare standardized from 1860 onwards only



Standardization research

- Spelling practices vary by community.
- Mechanisms and developments may depend on particular circumstances.
- How did this take place for (some of) Estonian?



Estonian in the late 19c

- From 1800-1900:
 - Peasant population becomes independent
 - Quick developments in education
 - Literacy from 20% to 95%
 - Intense travel and movement
 - Urbanization, railroads
 - Social and cultural modernization
 - Cultural production and identity
 - Strive to become a nation



Language standardization

- One form instead of many (colour & color -> color)
- How can this happen?
 - Talk like your neighbour
 - Follow a book
 - Survive longer
- For mechanisms, we should follow the process



Finding the data

What is needed? What is available?



Texts



- To study writing, we need texts:
 - Ideally from a variety of people
 - Education, dialect, profession
- Sources:
 - Linguistic corpora
 - Digitized works

Linguistic corpora

- Linguistic corpora are balanced collections of texts to facilitate language research.
- For the period, there's two:
 - Written Estonian Corpus
 - some 300 book snippets in 1890-1930
 - Old Written Estonian Corpus
 - all texts 1500-1700, some 50 texts from later

- Small-ish and not much metadata

Eesti Kirjakeele Korpus: 1890ndad

Statistika ja bibliograafia

- Korpuse koostisosad valdkondade kaupa.
- Algallikad paberkandjatel failide kaupa.


Tekstid

Märgendamata tekst, iga lause eraldi real

- Ajakirjandustekstid (zip-fail 586 Kb)
- Ilukirjandustekstid (zip-fail 438 Kb)

Vana kirjakeele korpus

[Avaleht](#) [Otsing](#) [Juhend](#) [Tekstid](#) [Väljaanded](#)




Esimene Eesti trükitud eestikeelne raamat (Stahl, 1637)

Eesti vana kirjakeele korpus sisaldab 15. kuni 19. sajandi tekste. Vanemad tekstid on morfoloogiliselt märgendatud, st neist tekstidest saab infot otsida sõnade tänapäevases kirjavisis algvormide ning vorminfo järgi.

- 15. ja 16. sajandist on korpusesse lisatud kõik teadaolevad ja säilinud eestikeelsed tekstid (va nimeloendid), nii käsikirjad kui ka trükitised.
- 17. sajandist on korpusesse lisatud enamik säilinud trükitexte.
- 18. ja 19. sajandist on lisatud valik trükitexte. Märgendatud on osa tekstidest.
- 19. sajandi II poolest on lisatud vallakohtute protokollid, mis on automaatselt märgendatud, vt täpsemalt M.-L. Pilvik, K. Muischnek, G. Jaanimäe, L. Lindström, K. Lust, S. Orasmaa, T. Tärna "Moistus sai kuulotudu: 19. sajandi vallakohtuprotokollide tekstidest digitaalse ressursi loomine".


Linguistic corpora

- Texts have high quality (though spelling was not in focus)
- Relatively small though.



Digitized texts

- For the past 20-30 years, a huge number of texts have been digitized.
 - In various collections and formats
 - With varying editing practices



Examples of text collections

- A variety of interfaces and access points
 - Usually text mining is not an option they consider
 - But don't mind either

Search

All of DSpace

Go

Date issued: [1800 TO 1940] ×

Show Advanced Filters

Tühjenda Otsi

Leitav Pala Arhiiv Eesti Kultuurilooline Arhiiv (EKLA) Kataloog Kõik

Üldised kitsendused

Ükskõik milline tunnus sisaldab

☐ Ainult failiga kirjed

☒ Ainult tekstiga kirjed

Näita korraga 10 Sorteeeri viide tähestikuliselt A-Z

Tühjenda Otsi Rohke

Tingimustele "Ilmumisaeg: 1800 - 1940, Keel: eesti" leidis 11566 vastet

Vastavuse alusel ▼

< 1 2 3 ... 1156 1157 >

Ava otsing



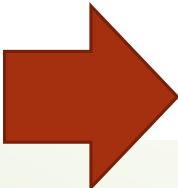
Ernst Moritz Arndt, Charles Dickens, J. Falck, Ira Kase, Martin Luther

Häadele lastele : jõulujutte ja -luuletusi

Kirjastaja: Elav Sõna. Ilmumisaeg: 1937

Getting the text

- Files of different format into text

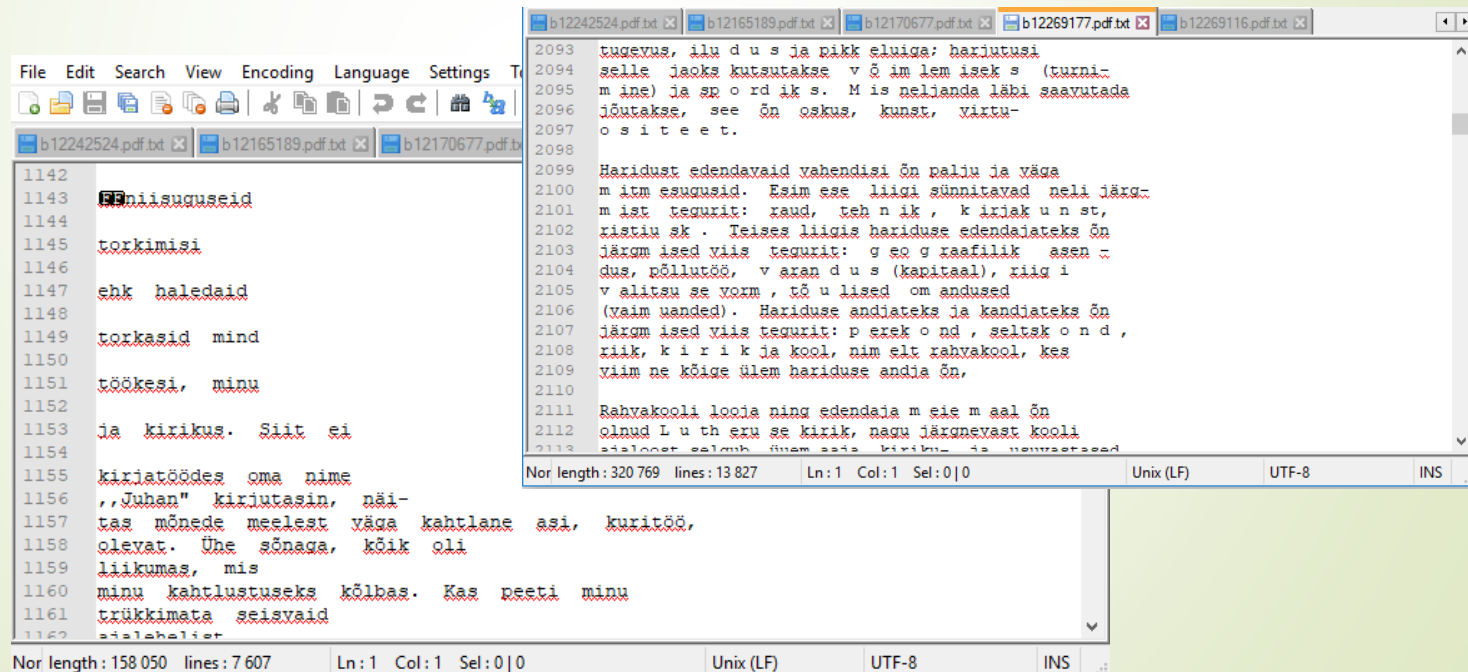


Name	Date modified	Type	Size
b11700956.pdf	24.07.2018 15:53	PDF-XChange Vie...	10 707 KB
b11706144.pdf	24.07.2018 15:57	PDF-XChange Vie...	281 960 KB
b11706399.pdf	24.07.2018 15:57	PDF-XChange Vie...	38 997 KB
b11715613.pdf	24.07.2018 15:57	PDF-XChange Vie...	3 156 KB
b11715674.pdf			
b11716289.pdf			
b11719990.pdf			
b11725795.pdf			
b11725801.pdf			
b11736744.pdf			
b11743098.pdf			

Name	Date modified	Type
b12164525.pdf.txt	30.06.2019 17:44	Notepad++ Docu...
b12165189.pdf.txt	30.06.2019 17:44	Notepad++ Docu...
b12170677.pdf.txt	30.06.2019 17:44	Notepad++ Docu...
b12206933.pdf.txt	30.06.2019 17:44	Notepad++ Docu...
b12218820.pdf.txt	30.06.2019 17:44	Notepad++ Docu...
b12219873.pdf.txt	30.06.2019 17:44	Notepad++ Docu...
b12224467.pdf.txt	30.06.2019 17:44	Notepad++ Docu...
b12227730.pdf.txt	30.06.2019 17:44	Notepad++ Docu...
b12228424.pdf.txt	30.06.2019 17:44	Notepad++ Docu...
b12239793.pdf.txt	30.06.2019 17:44	Notepad++ Docu...
b12242524.pdf.txt	30.06.2019 17:44	Notepad++ Docu...

Getting the text

- Finally, will have files that contain raw text
 - Quality will vary



```
File Edit Search View Encoding Language Settings T...
b12242524.pdf.txt b12165189.pdf.txt b12170677.pdf.txt b12269177.pdf.txt b12269116.pdf.txt
1142
1143 Ennissuguseid
1144
1145 torkimisi
1146
1147 ehk haledaid
1148
1149 torkasid mind
1150
1151 töökesi, minu
1152
1153 ja kirikus. Siit ei
1154
1155 kirjatöödes oma nime
1156 „Juhan“ kirjutasin, näi-
1157 tas mõnede meelest väga kahtlane asi, kuritöö,
1158 olevat. Ühe sõnaga, kõik oli
1159 liikumas, mis
1160 minu kahtlustuseks kõlbas. Kas peeti minu
1161 trükkimata seisvaid
1162 aialahelid

Nor length: 158 050 lines: 7 607 Ln: 1 Col: 1 Sel: 0|0 Unix (LF) UTF-8 INS

2093 tugevus, ilu d u s ja pikk eluiga; harjutusi
2094 selle jaoks kutsutakse v õ im lem isek s (turni-
2095 mine) ja sp o rd ik s. M is nelianda läbi saavutada
2096 lõutakse, see õ n oskus, kunst, virtu-
2097 os i t e e t.
2098
2099 Haridust edendavaid vahendisi õ n palju ja väga
2100 m itm esugusid. Esim ese liigi sünnitavad neli järg-
2101 m ist tegurit: raud, teh n ik , k irjak u n st,
2102 ristiu sk . Teises liigis hariduse edendajateks õ n
2103 järgm ised viis tegurit: g eo g raafilik asen -
2104 dus, põllutöö, v aran d u s (kapitaal), riig i
2105 v alitsu se vorm , t õ u lised om andused
2106 (vaim uanded). Hariduse andjateks ja kandjateks õ n
2107 järgm ised viis tegurit: p erek o nd , seltak o n d ,
2108 riik, k i r i k ja kool, nim elt rahvakool, kes
2109 viim ne kõige ülem hariduse andja õ n,
2110
2111 Rahvakooli looja ning edendaia m eie m aal õ n
2112 olnud L u th eru se kirik, nagu lähnevast kooli
2113 ajalooet selgub ühem aia kiriku- ja uueaastased

Nor length: 320 769 lines: 13 827 Ln: 1 Col: 1 Sel: 0|0 Unix (LF) UTF-8 INS
```

Metadata

- Again in various formats
- Ought to be collected

```
pro0004 Bornhöhe, Eduard "Tallinna narrid ja narrikesed" 1892 lk 3-12
pro0005 Bornhöhe, Eduard "Willu võitlused" 1890 lk 5-43
pro0006 Bornhöhe, Eduard "Würst Gabriel" 1893 lk 229-240
pro0007 Eisen, M. J. "Hiiru köster ja Saare kirikhärra" 1893 lk 43-52
pro0008 Eisen, M. J. "Tartu saladused" 1891 lk 7-18
pro0009 [??] "Hella" 1890 lk 3-12
pro0010 Hermann, K. A. "Lapse mälestus" 1896 lk 1-8
pro0011 Hermann, K. A. Rikka ja waese pulmad. Külajutukene. 1899 Lk. 29-37
pro0012 Hermann, K. A. Uudisjutud Eesti rahwa elust. 1895 Lk. 37-45
pro0013 [??] "Hugo ja Tekla". Jutustus Toolse (ranna) lossist ja ritterist, mis seal 15. aast
pro0014 Tüll, Heima imelikud juhtumised wõera mere-saarte peal. 1891
pro0015 Jaanus, Ein einfeltige weise zu
pro0016 Jakobson Beten, für einen guten
pro0017 Järw, J. freund Mart. Luther.
```



View/Open
f_III_1_252_10.pdf
(17.68Mb)
Tekstifailidega
(1.431Mb)

Date
1535

Author
Luther, Martin

Metadata
[Show full item record](#)

sordiaretaja

1.IX 1883 Harjumaal Kloostri valla Karilepa-Tõnul.
Taluperemees Siim A., Liisa Vraeger. Ae 1917 Anna Maria Volmer. Ants (1918, vt), Valve Jaagus (1920, vt), Ilmar (1927--92, vt). Vasalemma vallakool 1893--97, Paldiski algkool 1897--1900, Haapsalu linnakool 1902--03, Peterburi linnukasvatuskursus 1911--12, põllumajandusdoktor 1947. Sõjaväes Peterburis, vangistatud 1905--06, I maailmasõjas suurtükiväeametnik Tallinnas 1914--16, Eesti Sõjaväelaste Keskbüroo juhatuse liige, Harju maakonnakoostööliige ja sekretär 1917--20, 1918 Eesti diviisi staabi mobilisatsiooniosakonna asjaajaja, Vabadussõjas ülemjuhataja staabi majandusülem, Eesti Sordiparanduse Seltsi Jõgeva sordikasvatuse osakonnajuhataja 1920--50, "Väikelooma-kasvataja" toimetaja 1919--21, ENSV TA korrespondentliige 1946, UN 1947--50 (II ks); ENSV teeneline teadlane 1945, NE preemia 1947, Stalini preemia 1948. Surnud 19.I 1950 Jõgeval, maetud Tartu Raadi kalmistule. EAT, EE, EBLI, EAT2, ENE1, ENE2, EABL, VjV, ENE2(14), ETeadBL – ISOTAMM 2

Metadata

- General indexes (e.g. Estonian National Bibliography)

Estonian
National
Bibliography

Publication info

Links to digitized text

Person entry ids

RAHVUSRAAMATUKOGU
AVAANDMED

data.digar.ee



Search

DIGAR

DEA

ERB

ISIKUD/KOLLEKTIIVID

Andmekaevurile

VIAF
Näidiskirje

ISIKUD MARC21XML
formaadis

VIAF
Näidiskirje

ISIKUD RDF formaadis

MARC21XML
OAI-PMH

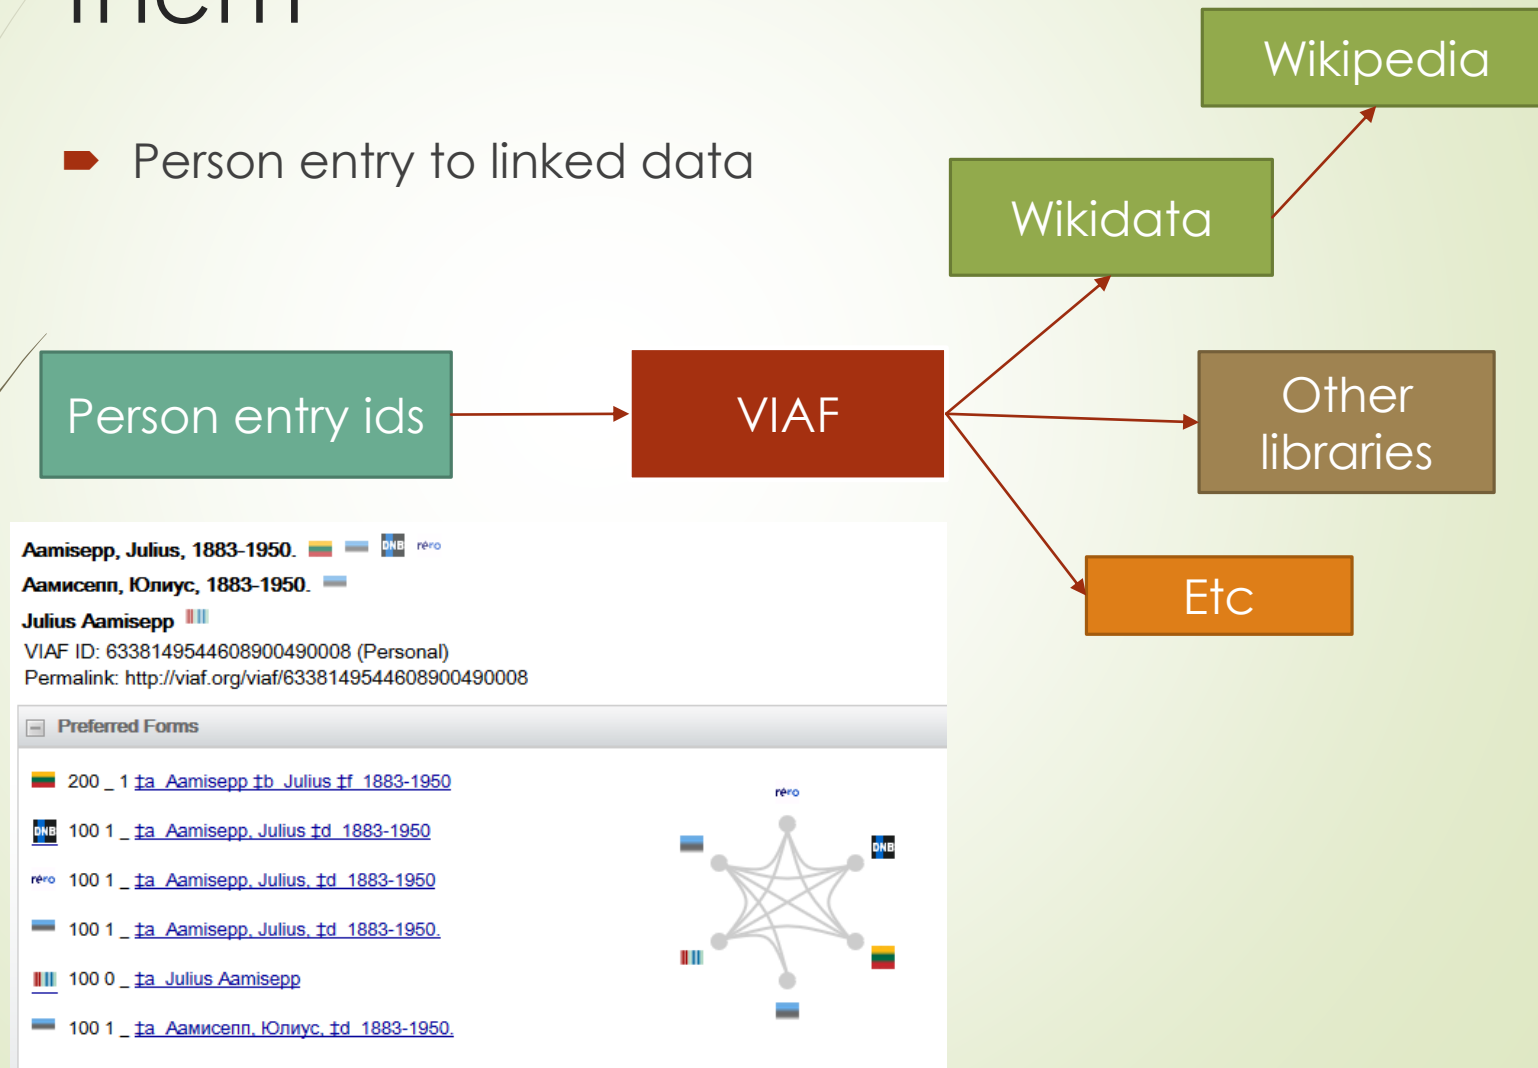
Eestikeelne raamat

MARC21XML
OAI-PMH


Muukeelne raamat

Collecting them all, linking them

➤ Person entry to linked data



Aggregating the data



001	ERRR a11124581 (VIAF cluster)
003	ERRR
008	990322 n adnnnaabn a
035	‡a (ERRR)a11124581
040	‡a ErRR ‡b est ‡c ErRR ‡d ErTUR
043	‡c ee
100	1 ‡a Aamisepp, Julius, ‡d 1883-1950.
400	1 ‡a Aamisepp, Julius.
500	1 ‡a Аамисепп, Юлиус, ‡d 1883-1950.
670	‡a EE, 1. kd., 1985; EE, 14. kd., 2000.
680	‡i Eesti põllumajandusteadlane, sordiaretaja, põllumaj

100	1 ‡a Aamisepp, Julius ‡d 1883-1950
375	‡a 1 ‡2 iso5218
500	1 ‡0 (DE-101)1096201100 ‡0 (DE-588)1096201100 ‡0 http://d-nb.info/gnd/Aamisepp, Ilmar ‡d 1927-1992 ‡4 bezf ‡4 http://d-nb.info/standards/elementset/gnd#familialRelationship ‡w r ‡i Beziehung familia ‡e Beziehung familia ‡a 1883-1950 ‡4 datl ‡4 http://d-nb.info/standards/elementset/gnd#dateOf ‡w r ‡i Lebensdaten
548	‡a 01.09.1883-19.01.1950 ‡4 datx ‡4 http://d-nb.info/standards/elementset/gnd#dateOfBirthAndDeath ‡w r ‡i Exakte Lebensdaten
560	‡0 (DE-101)04203194X ‡0 (DE-588)4203194-1 ‡0 http://d-nb.info/gnd/4203194-1 ‡a Agrarwissenschaftler ‡4 berc ‡4 http://d-nb.info/standards/elementset/gnd#professionOrOccupation ‡w r ‡i Charakteristischer Beruf
560	‡0 (DE-101)041779436 ‡0 (DE-588)4177943-5 ‡0 http://d-nb.info/gnd/4177943-5 ‡a Revolutionär ‡4 beru ‡4 http://d-nb.info/standards/elementset/gnd#professionOrOccupation ‡w r ‡i Beruf
561	‡a Karilepa ‡4 ortg ‡4 http://d-nb.info/standards/elementset/gnd#placeOfBirth ‡w r ‡i Geburtsort ‡9 v:Gem. Lääne-Harju



Sisse logimata Artetelu Kaastöö Loo konto Logi

Artikkel **Arutelu** Vaata Muuda Muuda lähteteksti Näita ajalugu Otsi Vikipeediast

Julius Aamisepp

Julius Aamisepp (1 september (vkj 20. august) 1883 Harjumaa, Kloostri vald, Karilepa, Karilepa-Tõnu talu – 19. jaanuar 1950 Jõgeva) oli eesti sordiaretaja.

Eesti biograafiline andmebaas ISIK

avalehekülg · nimekiri ja otsing · ametikohad (110) · asutused (470) · isikud (446) · kaastööd väljaannetele (1133) · nime etrükkud (722) · pseudonüümid (9179) · sugulased (209) · sünnikohad (623) · surmakohad (186) · tegevusala (399) · lähendid ja allikad · admin

AAMISEPP, JULIUS	
Nimi	
Nime normitud kuju	Aamisepp, Julius
Eluandmed	
Sünniaeg	1883-09-01
Sünnikoht	Karilepa-Tõnu t. Kloostri v. Harjumaa.
Surmaaeg	1950-01-19
Surmakoh	Jõgeva
Märkus	maetud Tartu Raadi kalmistule
Üldandmed	
Tegevusala	sordiaretaja
Biograafilised andmed	
1.IX 1883 Harjumaa Kloostri valla Karilepa-Tõnu t. Taluperemees Sim A., Lise Viager. Ae 1917 Anna Maria Volmer. Arts (1918, vt), Valve Jaagus (1920, vt), Ilmar (1927–92, vt), Vasalemma vallakool 1893–97, Paldiski algkool 1897–1900, Haapsalu linnakool 1902–03, Peterburi linnakaasvatuskursus 1911–12, põllumajandusdoktor 1947, sõjaväes Peterburis, vangistatud 1905–06, 1 maailmasõjas suurtükiväeametnik Tallinnas 1914–16, Eesti sõjaväelaste Keskbüroo juhatusel ligi, Harju maakonnandukogu liige ja sekretär 1917–20, 1918 Eesti diviisi staabi mobilisatsiooniosakonna asjaajaja, Vabariigisõjas ülemjuhataja staabi majandusleht, Eesti Sordiparanduse Seltsi Jõgeva sordikasvatuse osakonnajuhataja 1920–50, "Vaskeloma-kasvataja" toimetaja 1918–21, ENSV TA korrespondentliige 1946, UN 1947–50 (11 ks); ENSV teeneline kaadlane 1945, NE preemia 1947, Stalini preemia 1948. Surmud 19.1 1950 Jõgeval, maetud Tartu Raadi kalmistule. EAI, EE, EBU, EAT2, ENE1, ENE2, EABL, VJ, ENE2(14), ETEADBL – ISOTAMM 2	

Manual linking

Manual linking

B11643												
	A	B	C	D	E	F	G	H	I	J	K	L
11640	TRUE								Lorup, Johannes	Lorup, Johannes		
11641	TRUE								Loskit, Juhan	Loskit, Juhan		
11642	TRUE								Loskit, Karl	Loskit, Karl		
11643			ISIK	1908					Lossius, Eduard	Lossius, Eduard	Lossius, Eduard	1811-09-05
11644	TRUE		ISIK	1908					Lossius, Eduard	Lossius, Eduard		
11645	TRUE								Losski, Nikolai	Losski, Nikolai		
11646			VEPP	1549					Lossman, Helmar	Lossman, Helmar	Lossman, Helmar	07.02.1903
11647			VEPP	4083					Lossman, Juri	Lossman, Juri	Lossman, Juri	04.02.1891
11648	TRUE		VEPP	4084					Lossmann, Arthur	Lossmann, Arthur		
11649			VEPP	4084					Lossmann, Artur	Lossmann, Artur	Lossmann, Artur	05.10.1877
11650			ISIK	1909					Lossmann, August-Postimees	Lossmann, August-Postimees	Lossmann, August-Postimees	1857-1907
11651	TRUE								Lossmann, J	Lossmann, J	Lossmann, J	1871-12-26
11652			ISIK	1910					Lossmann, Jaan	Lossmann, Jaan	Lossmann, Jaan	1866-00-00
11653	TRUE	unsure	ISIK	1910					Lossmann, Jaan	Lossmann, Jaan	Lossmann, Jaan	
11654	TRUE								Lossmann, Juri	Lossmann, Juri	Lossmann, Juri	
11655			VEPP	3238					Lossmann, Peeter	Lossmann, Peeter	Lossmann, Peeter	24.03.1919
11656			ISIK	1911					Lotariov, Igor Vassilievits	Lotariov, Igor Vassilievits	Lotariov, Igor Vassilievits	1887-05-16

Σ = ILU1910_ilu0077						
RRid	filename	aasta	isik.id	other_source	canonical_name	
b16019891	ADO REINWALD I LAULUD - Ado Reinwald	1904	2288		Reinwald, Ado	
b15181315	ILU1910_ilu0037	1913	6865		Kann, Aleksander	
b1663438x	1845-Umbilia.txt	1845		EEVA		
b14946750	ILU1910_ilu0017	1910	3235		Ertel, Alide	
b11478779	POGENENUD KLOOSTRI KASVANDIK - Ar	1885	2471		Saal, Andres	
b16120516	saal_wambola_9789949530670.txt	1889	2471		Saal, Andres	
b1497096x	SOSTRA-SILMAD - Andres Saal.txt	1890	2471		Saal, Andres	
b1496935x	Aita - Andres Saal.txt	1891	2471		Saal, Andres	
b12698180	saal-parisjaprii.txt	1891	2471		Saal, Andres	
b11494487	UUDU JA MEETA - Andres Saal.txt	1892	2471		Saal, Andres	
b14974265	PARIS JA PRIL. 2 - Andres Saal.txt	1893	2471		Saal, Andres	
b12072655	LUULETUSED - Anna Haava.txt	1888	4802		Haavakivi, Anna	
b14668026	LUULETUSED. Teine vihik - Anna Haava.txt	1890	4802		Haavakivi, Anna	
b11327121	LUULETUSED.Kolmas vihik - Anna Haava.txt	1897	4802		Haavakivi, Anna	
b13472422	Lained - Anna Haava.txt	1906	4802		Haavakivi, Anna	
b14668257	RIST-LAINED - Anna Haava.txt	1910	4802		Haavakivi, Anna	
b14668294	ILU1910_ilu0031	1911	4802		Haavakivi, Anna	
b11529817	POHJAMAA-LAPSED - Anna Haava.txt	1913	4802		Haavakivi, Anna	

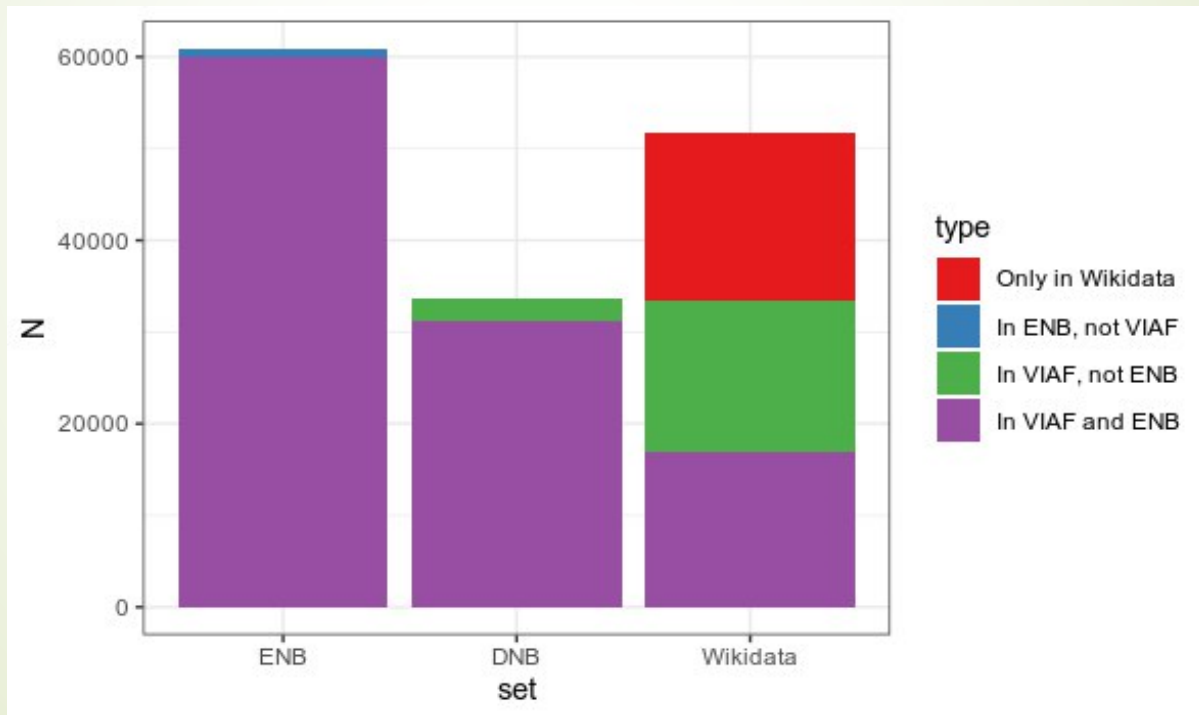
Harmonization

- For archival purposes, accuracy is key.
- For analysis, data harmonization is often needed.

```
28
29 #works <- works#[!is.na(koht),.N,by=koht]
30 works <- works[,koht:=str_replace_all(koht,"s$","")]
31 works <- works[,koht:=str_replace_all(koht,"l$",")]
32 #works <- works[!duplicated(works)]
33 #places[places!="&places!="S.l."&places!="S.l."&places!="S.l."&places!="S.l."]
34 works <- works[koht!="&koht!="S.l."&koht!="S.l."&koht!="S.l."&koht!="S.l."]
35 works[str_detect(koht,"Paide"),koht:="Paide"]
36 works[str_detect(koht,"Weissenstein"),koht:="Paide"]
37 works[str_detect(koht,"Вейсенштейн"),koht:="Paide"]
38 works[str_detect(koht,"Вейсенштейн"),koht:="Paide"]
39 works[str_detect(koht,"Haapsalu"),koht:="Haapsalu"]
40 works[str_detect(koht,"Hapsa"),koht:="Haapsalu"]
41 works[str_detect(koht,"Гансаль"),koht:="Haapsalu"]
42
43 works[str_detect(koht,"Keila"),koht:="Keila"]
44 works[str_detect(koht,"Rakvere"),koht:="Rakvere"]
45 works[str_detect(koht,"Wesenberg"),koht:="Rakvere"]
46 works[str_detect(koht,"Везенберг"),koht:="Rakvere"]
47
183 works[kirjastus=="w.borni pär.",kirjastus:="k.a.hermann"]
184 works[kirjastus=="f.w.born",kirjastus:="k.a.hermann"]
185 works[str_detect(kirjastus,"noor ee"),kirjastus:="k.a.hermann"]
186 works[str_detect(kirjastus,"nutsu"),kirjastus:="k.a.hermann"]
187 works[str_detect(kirjastus,"ploompui"),kirjastus:="k.a.hermann"]
188 works[str_detect(kirjastus,"postimees"),kirjastus:="k.a.hermann"]
189 works[str_detect(kirjastus,"postimees"),kirjastus:="k.a.hermann"]
190 works[str_detect(kirjastus,"h\\..laal"),kirjastus:="k.a.hermann"]
191 works[str_detect(kirjastus,"eesti kirjandus"),kirjastus:="k.a.hermann"]
192 works[kirjastus=="eesti kirjandus",kirjastus:="k.a.hermann"]
193 works[kirjastus=="hermann",kirjastus:="k.a.hermann"]
194 works[kirjastus=="hermann'i raamatukogu",kirjastus:="k.a.hermann"]
195 works[kirjastus=="pealadu hermanni raamatukogu",kirjastus:="k.a.hermann"]
196 works[kirjastus=="hermanni raamatukogu",kirjastus:="k.a.hermann"]
197 works[kirjastus=="hermann'i rmtkpl.",kirjastus:="k.a.hermann"]
198 works[kirjastus=="pealadu hermanni kaupluses",kirjastus:="k.a.hermann"]
199 works[kirjastus=="leoke'se kirjastus",kirjastus:="h.leoke"]
200 works[kirjastus=="leoke",kirjastus:="h.leoke"]
201 works[kirjastus=="leoke'se raamatutäri antikvariaat",kirjastus:="h.leoke"]
```

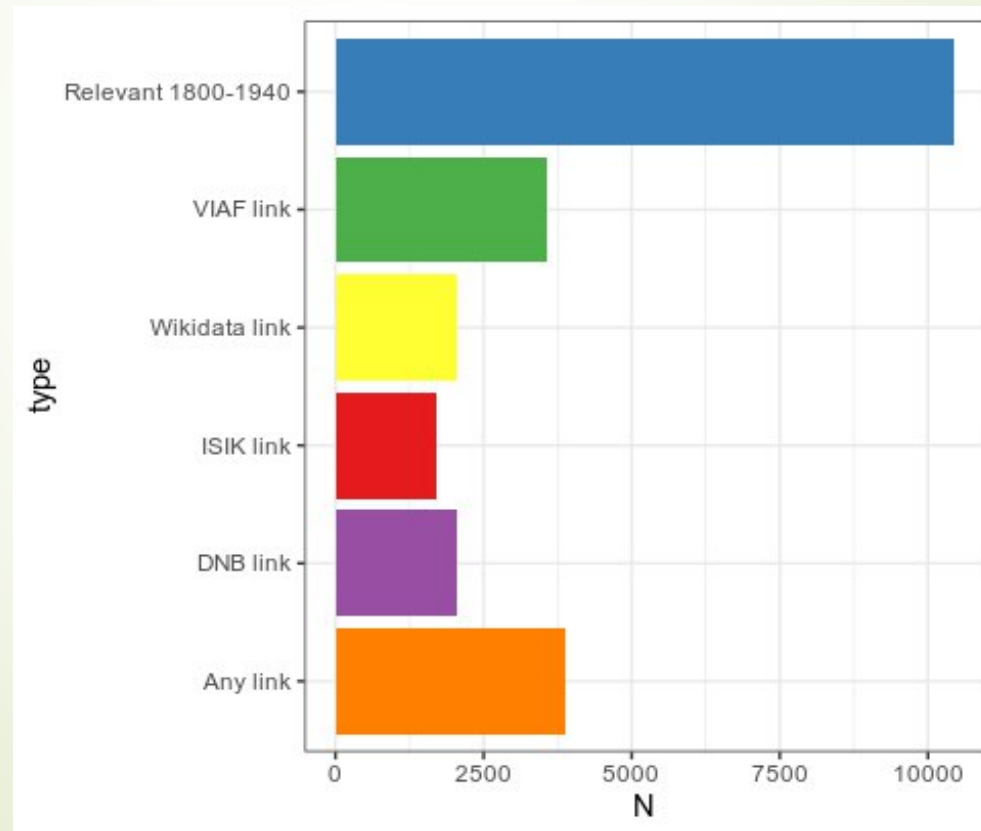

Results of linking

➤ Linkability of archives




Results of linking

➤ Linked author metainformation



Results of text collection

➤ 5132 texts total, of 4186 unique publications



Processing the corpus

- Raw texts can be processed
- Lemmatize, POS-tag etc (used Python EstNLTK)


```
from estnltk import Text
text = Text('mõeldud')
text.tag_analysis()
```

```
[('Usjas', 'A', 'omadussõna algvõrre'),
 ('kaslane', 'S', 'nimisõna'),
 ('ründas', 'V', 'tegusõna'),
 ('künklikul', 'A', 'omadussõna algvõrre'),
 ('maastikul', 'S', 'nimisõna'),
 ('tünjat', 'A', 'omadussõna algvõrre'),
 ('Tallinnfilmi', 'H', 'pärisnimi'),
 ('režissööri', 'S', 'nimisõna')]
```

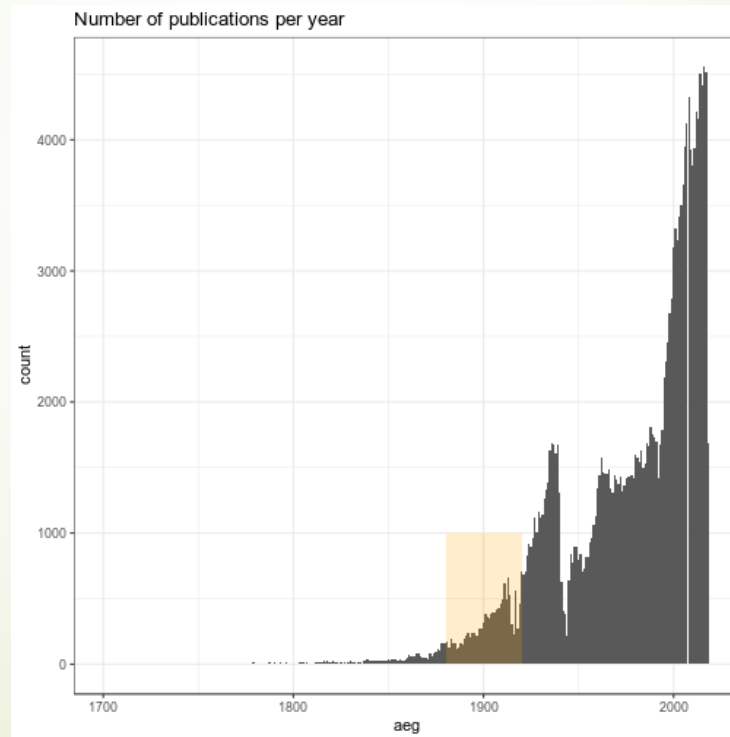
```
{'paragraphs': [{'end': 7, 'start': 0}],
 'sentences': [{'end': 7, 'start': 0}],
 'text': 'mõeldud',
 'words': [{'analysis': [{'clitic': '',
                          'ending': '0',
                          'form': '',
                          'lemma': 'mõeldud',
                          'partofspeech': 'A',
                          'root': 'mõel=dud',
                          'root_tokens': ['mõeldud']}],
             {'clitic': '',
              'ending': '0',
              'form': 'sg n',
              'lemma': 'mõeldud',
              'partofspeech': 'A',
              'root': 'mõel=dud',
              'root_tokens': ['mõeldud']}],
            {'clitic': '',
             'ending': 'd',
             'form': 'pl n',
             'lemma': 'mõeldud',
```

Results of the corpus

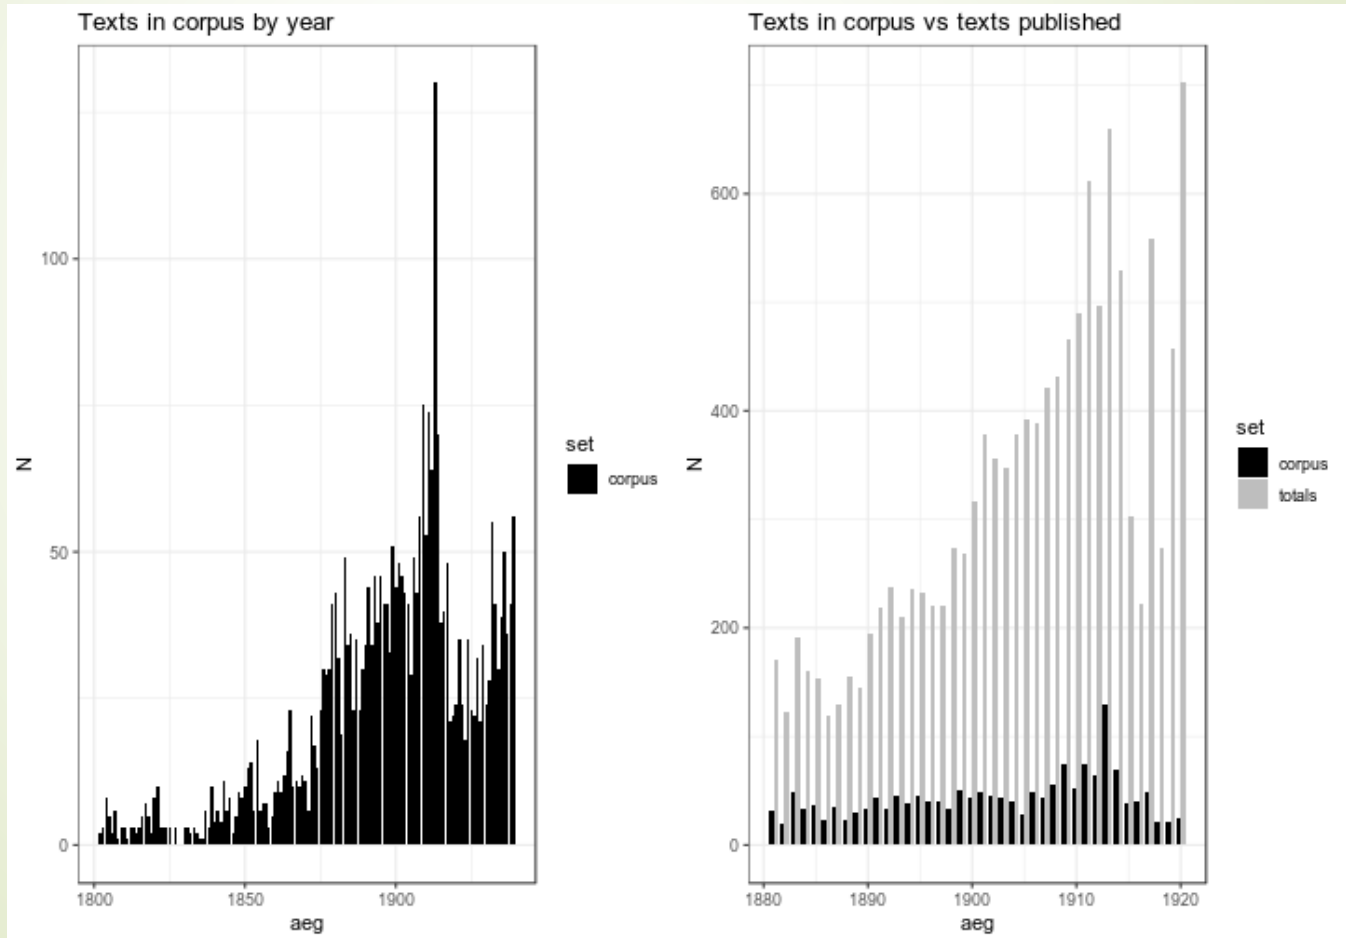
➤ NLP success rate over time



The published texts

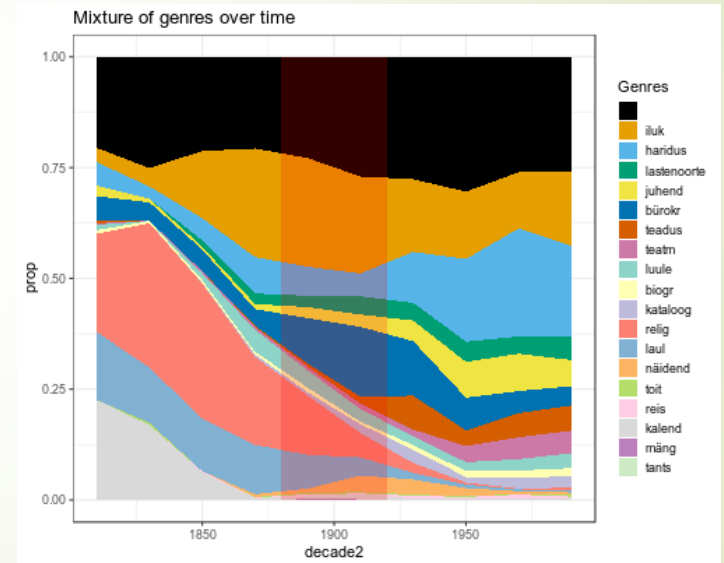



Representativeness




Publishing industry

➤ More authors and open genres






A few cities dominate




In corpus

➡ S




Publishers

➤ Top publishers (harmonized)




Publishers

- Top publishers (harmonized) within corpus



Authors

- Top authors (harmonized) within corpus





Other types of data

- There is a lot of relevant scholarship.
- Just thinking about it in terms of „data“ is new.
- Needs creativity in finding and utilizing the data

Biographic data

- Assemble life histories
 - from various sources



Eesti biograafiline andmebaas ISIK

avalehekülg · nimekiri ja otsing · ametikohad [108] · asutused [468] · isikud [4485] · kaastöö väljaannetele [1131] · nime erikujud [925] · pseudonüümid [9179] · sugulased [309] · sünnikohad [624] · surmakohad [188] · tegevusala [599] · lühendid ja allikad · admin

SAAL, ANDRES

Nimi

Nime normitud kuju **Saal, Andres**

Allikad Postimees 1857-1907, 235-236; EAE-40, lk. 200, EE (2000), XIV, lk. 447.

Eluandmed

Sünniaeg **1861-05-21**

Sünnikoht **Selja k. Tori v. Pärnumaa**

Surmaaeg **1931-06-23**

Surmakohht **Los Angeles**

Üldandmed

Tegevusala **kirjanik, õpetaja**

SAAL, Andres. 21.V 1861 **Tori khk Tori v Laasil** Taluom (ms puusepp) Jaak S. (1817--1902), Ano Lindebaum (ms toatüdr, 1818--92). Ae Emilie Rosalie Moks (1871--1954), Rosa Regina Boilev (1902--30, maalikunstn), Leo Henry Wladimir (1904--65, ins), **Selja v-k, Tori khk, vallak.õp eksam 1880, TU vabakuulaja 1886--89, Cronenbergi fototehnikak Baieris, Viini paljundustehnikainst, Selja v-k õp 1880--84, Oleviku toim.l 1884--90 ja tsinkograaf 1893--97, Trt Jaani kirik õp 1884--90, toiduainete kaupmees Trt-s 1890--93, fotograaf Frankfurdis 1897--98, fotograaf Jaaval 1898--1920, Los Angeleses 1920--31** jai pimedaks 1928. Kirjanik. Sm 23.VI 1931 Hollywoodis, tuhastati (urn 1932 Trt Maarja kir-s, 1944 kirj.muus-s). PmA, EBL, EE, EBL, ENE1, EKBL, EKrt, ENE2, EKoBL, ENE2(14)


Biograafilised andmed

Person	Aamisepp, Julius
Geschlecht	männlich
Quelle	Pressearchiv des Herder-Instituts Marburg Wikipedia (Stand: 25.09.2018): https://en.wikipedia.org/wiki/Julius_Aamisepp
Zeit	Lebensdaten: 1883-1950
Land	Estland (XA-EE)
Geografischer Bezug	Geburtsort: Karilepa (Gem. Lääne-Harju) Sterbeort: Jõgeva
Beruf(e)	Agrarwissenschaftler Revolutionär

Placename locations

Eesti Keele Instituudi kohanimeandmebaas (KNAB) Place Names Database (KNAB)

Päringud:



[Eesti kohanimed](#)

[7. I 2016: 45602 nimeobjekti / named features]

Queries / Поиск:



[Geographical names of Estonia](#)
[Географические названия Эстонии](#)

Kohanimi = rööp- või >> viit põhinimele
st: staatus *liik:* liik *mk:* maakond *lv:* linn või vald *khk:* kihelkond *lähik:* lähikuuluvus (asum vms)

Kuressaare k · [\[KNB\]](#)
st: P *liik:* p20: #H3658 *mk:* VD *lv:* Trv *khk:* Trv
koordinaadid: 58°12'22"N : 25°50'34"E [Maa-amet](#) [GeoNames](#)

Kuressaare laht · [\[KNB\]](#)
st: P *liik:* h32 *mk:* SA *lv:* Krs, LSr *khk:* Kaa (Krs)
koordinaadid: 58°13'35"N : 22°28'20"E [Maa-amet](#) [GeoNames](#)


Kuressaare linn · [\[KNB\]](#)
st: P *liik:* a2, p10: #H349 *mk:* SA *lv:* Krs *khk:* Kaa (Krs)
koordinaadid: 58°15'12"N : 22°29'10"E [Maa-amet](#) [GeoNames](#)

Kuressaare linnus
st: P *liik:* x2 *mk:* SA *lv:* Krs *khk:* Kaa (Krs) *lähik:* KL


Kuressaare maantee
st: P *liik:* u1 *mk:* SA *lv:* Lsi *khk:* Krj *lähik:* Leisi alevik

Birthplaces of writers

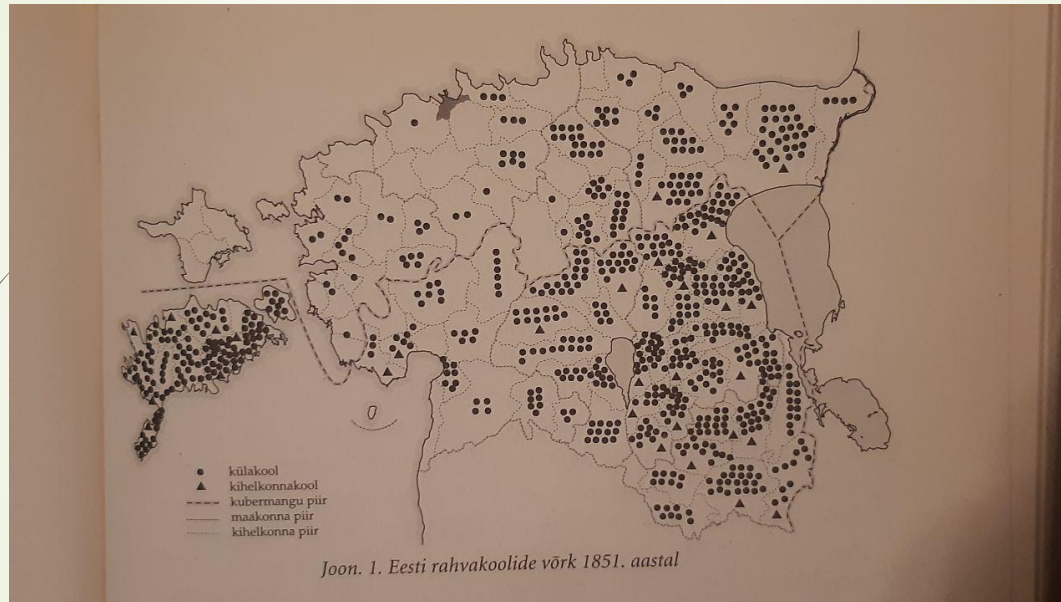
- Some birthplaces of writers in corpus



Birthplaces by decade



Education by decade

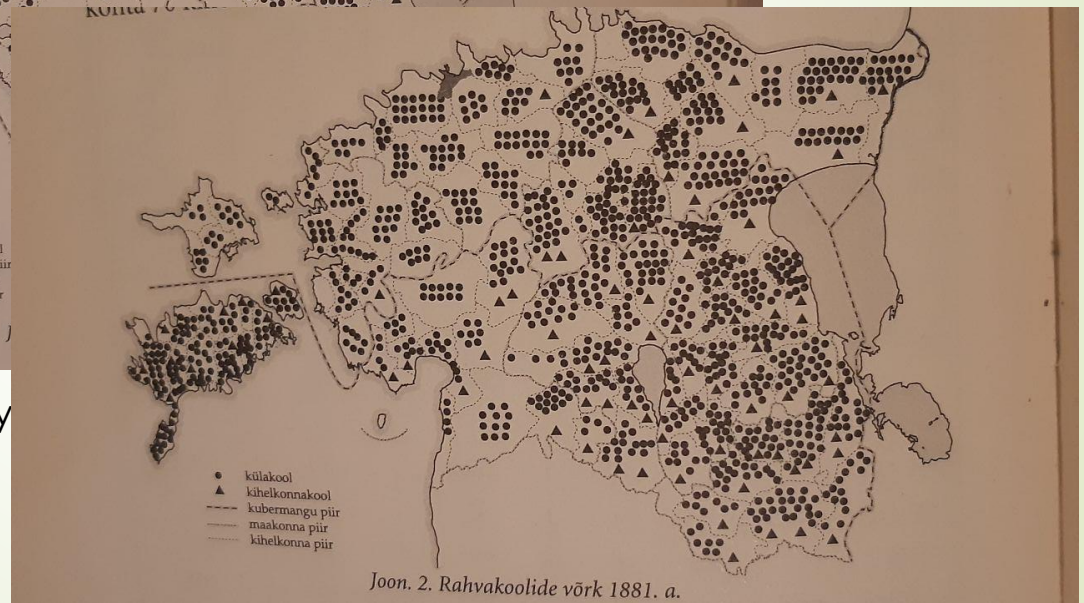


Public elementary school network in 1851

Education by decade




Public elementary



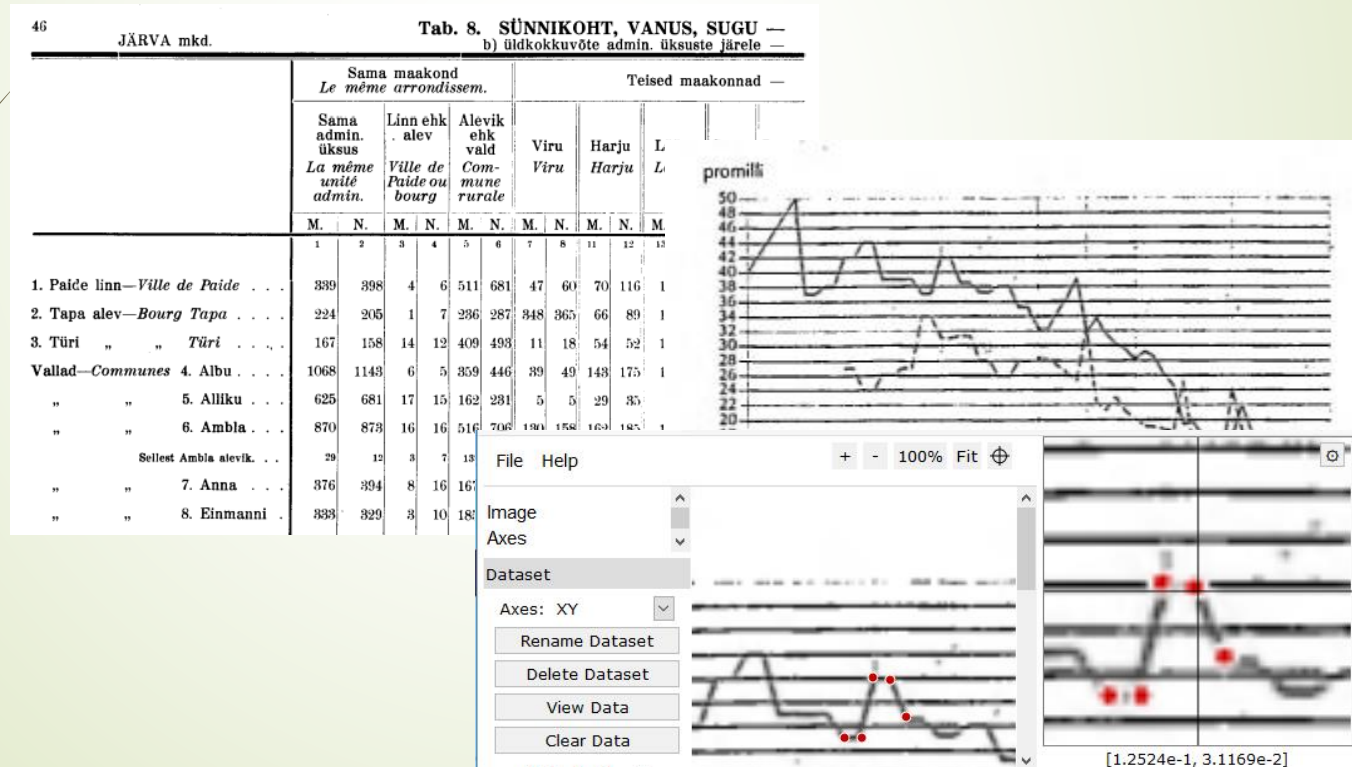
Public elementary school network in 1881

Life histories of writers




Demographic data

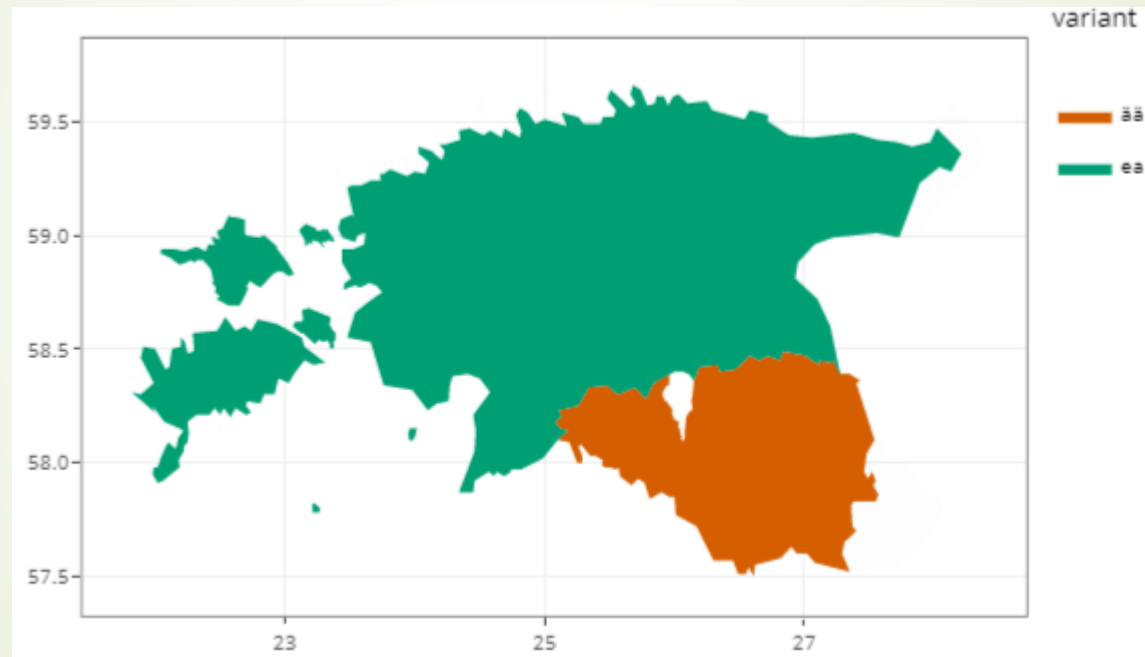
➤ Censuses and analyses



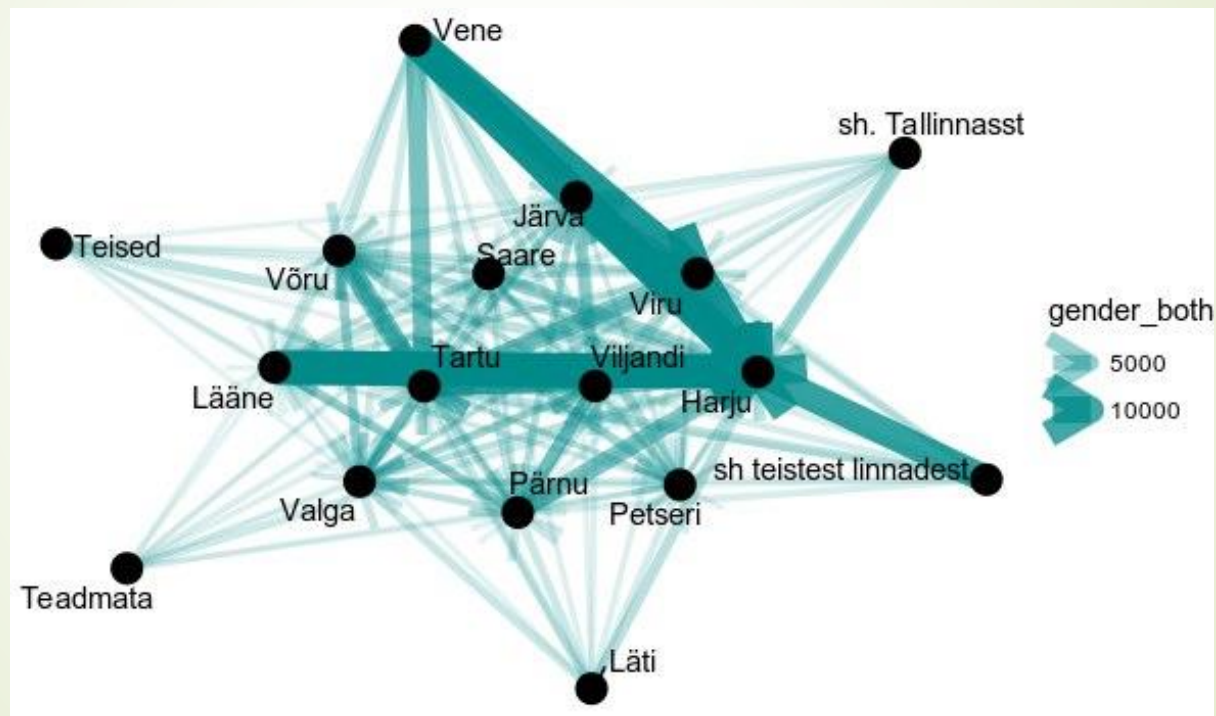
Dialect geography




Dialect predicted values



Dialect compositions in cities



Migration and dialects





Getting to research

Operationalizing the question



Making the study


- Specify the measured variables
- Measure in suitable texts
- Combine with metadata
- Check the mechanisms




Variants and variation

- A set of variables:
 - w / v – wabariik, vabariik
 - ää / ea – hää, hea; sääl, seal
 - üi / üü – nüid, nüüd
 - herra / härra
 - naine / naene
 - om / on
- Fairly common in frequency
- Have interesting variation in 1880-1920

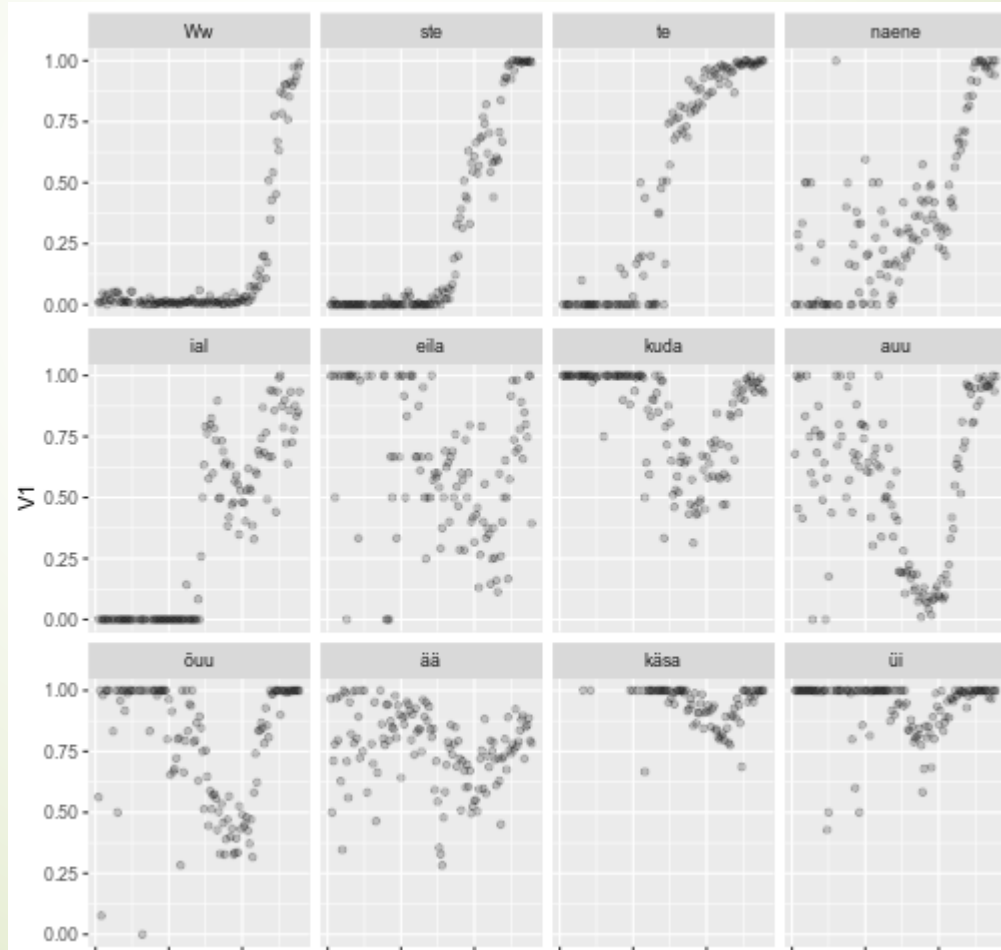
Variants and variation



Study on particular variants



Average trends



Language prescription

➤ Historian's overviews




- käänata sõna *juus* (=juuksekarv) järgmiselt: *juukse, juuksed, juuste*;
- käänata sõna *kodu* ainsuse omastavas *kodu* ja sisseütlevas *koju*;
- kirjutada *üü*, mitte *üi* sõnades nagu *nüüd, hüüdma, tüütama, süütama*;
- kirjutada *kaine, naine, laine*, mitte *kaene, naene, laene*, aga *naeris, paene* (sõnast *paas*), *vaene*; samuti *aed, aednik*, mitte *aid, aidnik*;
- kirjutada *kullassepp* (kahe *s*-iga), mitte *kullasepp*;
- kirjutada *herra, veevel*, mitte *härä, väävel*, aga *närvid*, mitte *nervid*;
- kirjutada *väike, kõik, löikama*, mitte *veike, keik, leikama*;
- kirjutada *kähar*, mitte *kähär*;

Overview of proposed norms in 1909 (Raag 2008)

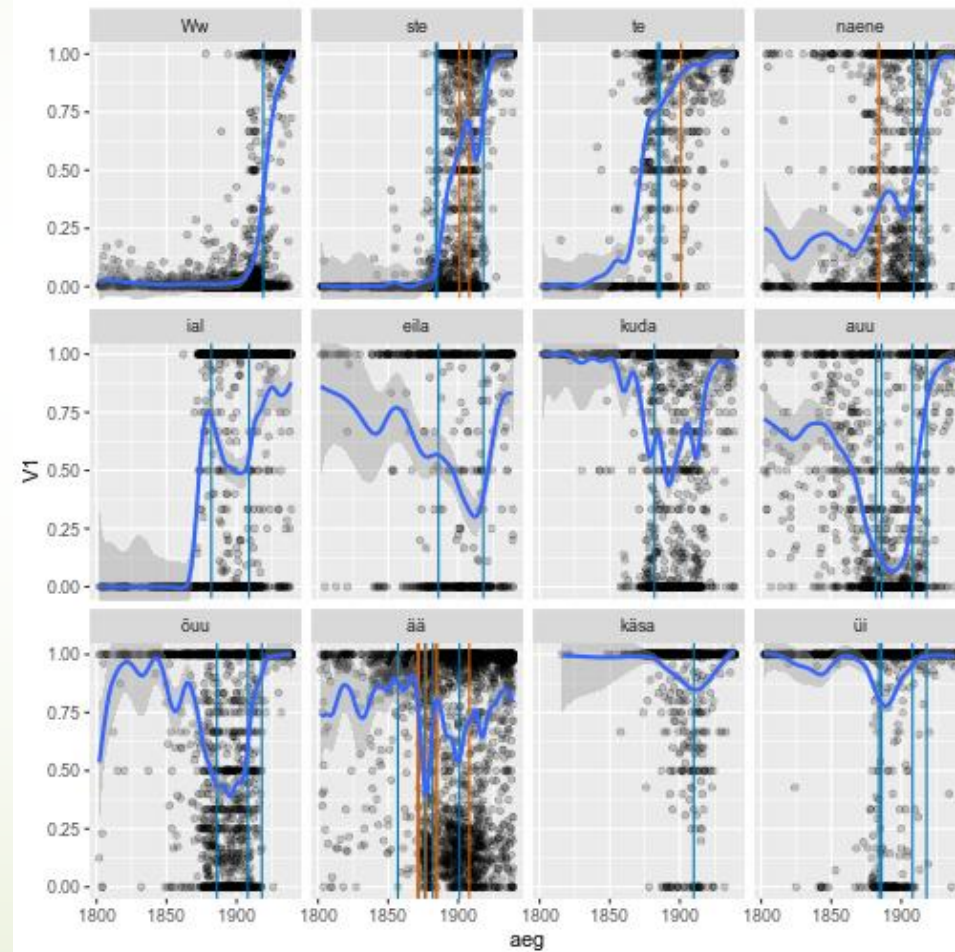
Language prescription

- Prescriptive events on the timeline
- Blue (suggested norm towards 1)
- Red (suggested norm towards 1)

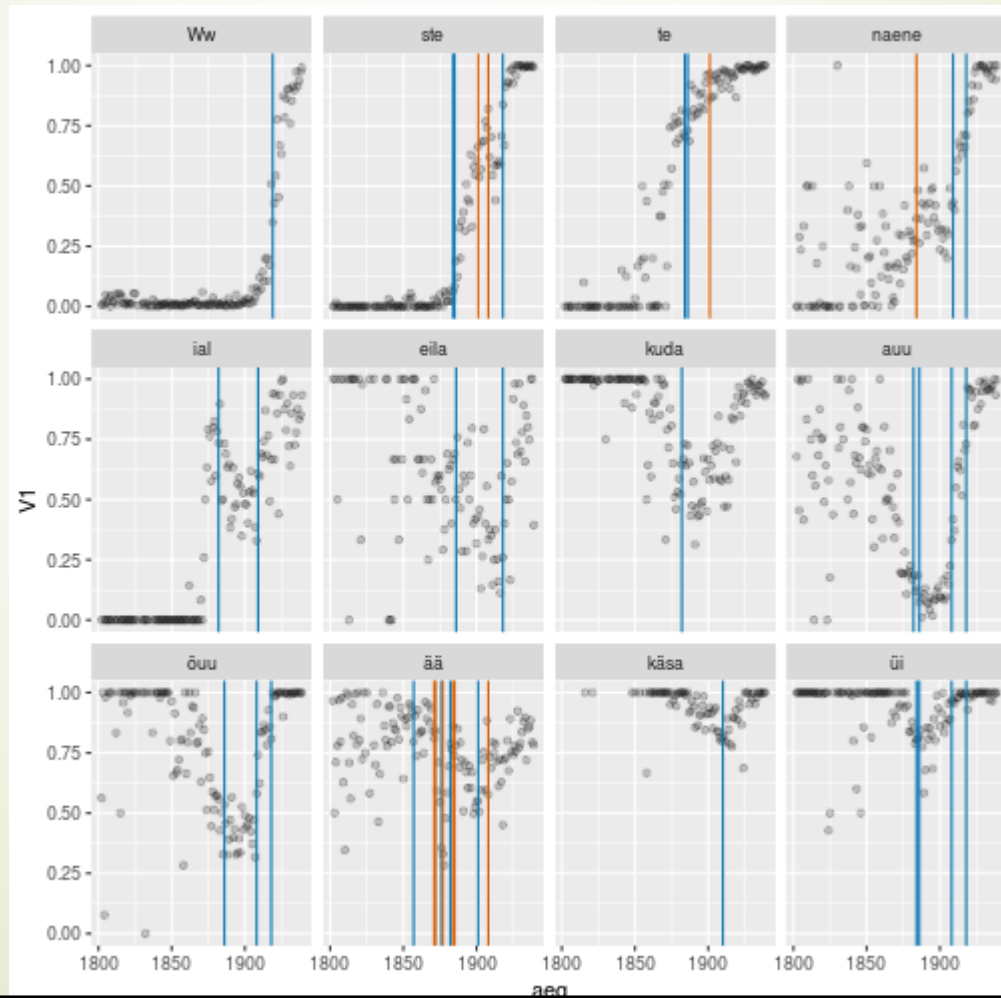


Language prescription

- Prescriptive events align very well with trends in usage.
- => at least some degree of prescriptive influence.



Language prescription



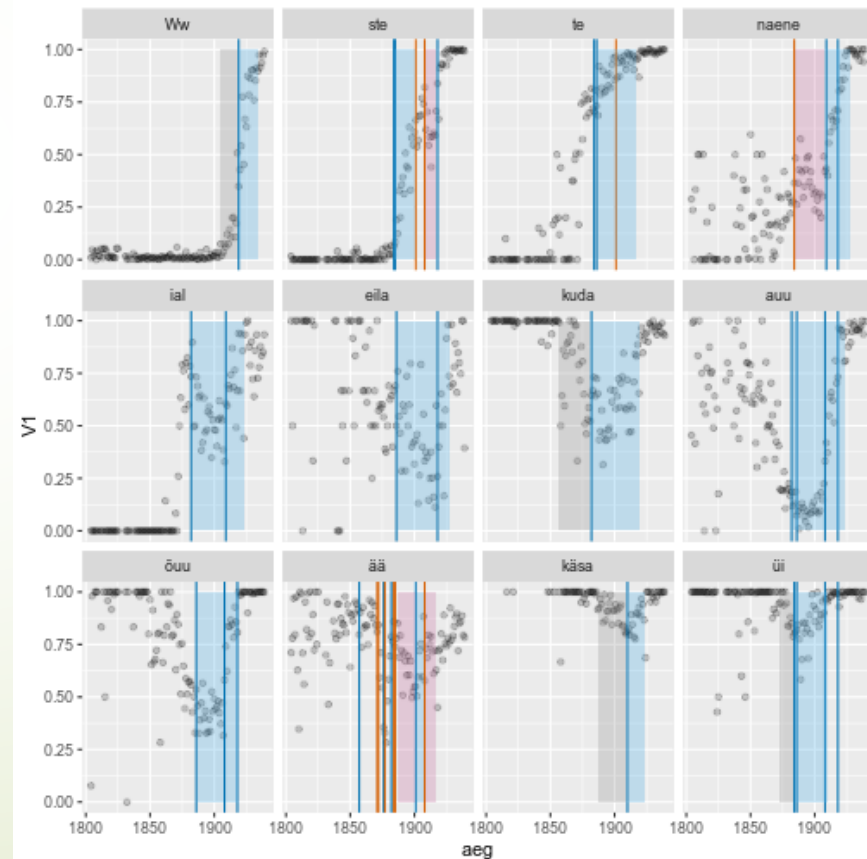


Mechanisms of standardization

- Influences on language usage
 - Home dialect
 - Everyday language use
 - Education
 - Prescription
 - Etc
- What made a suggestion successful?
- Generational change vs individual change?

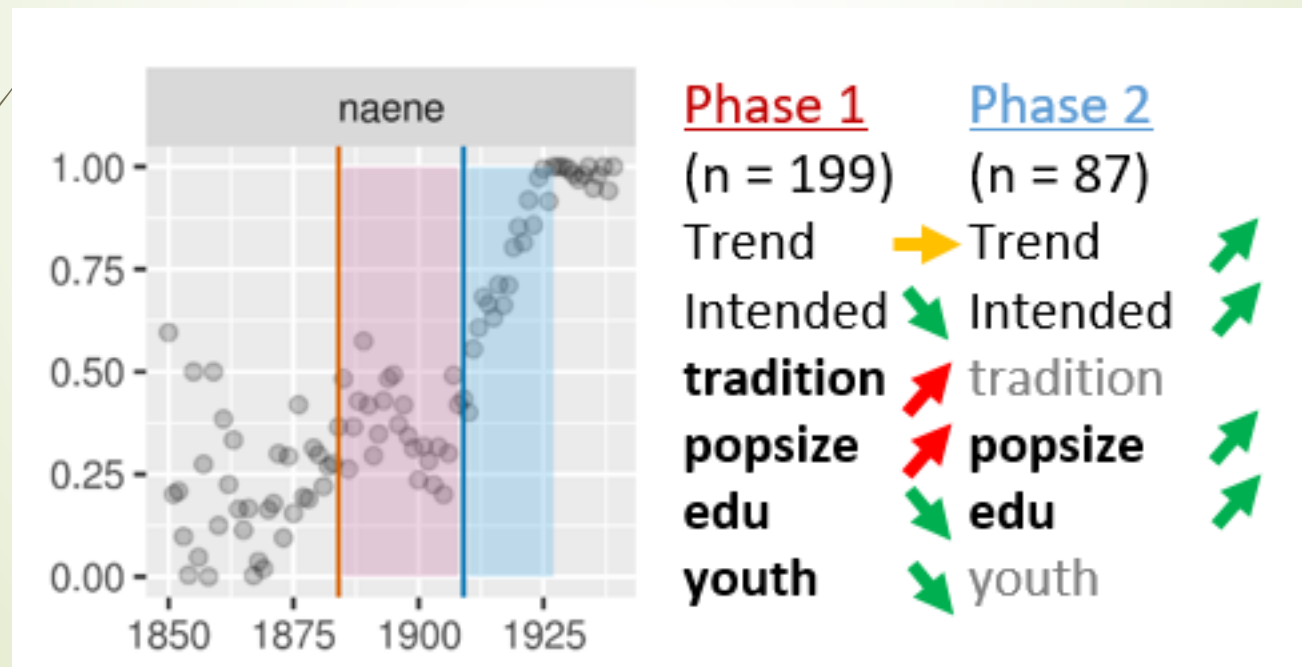
Phases of change

- Looking at the aftermath of prescriptive events
- Blue (suggested norm towards 1)
- Red (suggested norm towards 1)




Simple tendencies in data

- Significant predictors (logistic regression)
 - Model does not include dialect info




Simple tendencies in data

- Significant predictors (logistic regression)
 - Model does not include dialect info




Simple tendencies in data


- Significant predictors (logistic regression)
 - Model includes dialect info



Simple tendencies in data


- Significant predictors (logistic regression)
 - Model includes dialect info






Phase 1
(n = 91)
Trend
Intended
tradition
popsize
edu
youth

Phase 2
(n = 56)
Trend
Intended
tradition
popsize
edu
youth




Phase 1
(n = 170)
Trend
Intended
tradition
popsize
edu
youth

Phase 2
(n = 86)
Trend
Intended
tradition
popsize
edu
youth




Phase 1
(n = 265)
Trend
Intended
tradition
popsize
edu
youth




Phase 1
(n = 199)
Trend
Intended
tradition
popsize
edu
youth

Phase 2
(n = 87)
Trend
Intended
tradition
popsize
edu
youth




Phase 1
(n = 210)
Trend
Intended
tradition
popsize
edu
youth

Phase 2
(n = 71)
Trend
Intended
tradition
popsize
edu
youth



Phase 1
(n = 101)
Trend
Intended
tradition
popsize
edu
youth




Phase 1
(n = 117)
Trend
Intended
tradition
popsize
edu
youth

Phase 2
(n = 323)
Trend
Intended
tradition
popsize
edu
youth




Phase 1
(n = 206)
Trend
Intended
tradition
popsize
edu
youth

Phase 2
(n = 71)
Trend
Intended
tradition
popsize
edu
youth




Phase 1
(n = 200)
Trend
Intended
tradition
popsize
edu
youth

Phase 2
(n = 77)
Trend
Intended
tradition
popsize
edu
youth




Phase 1
(n = 158)
Trend
Intended
tradition
popsize
edu
youth

Phase 2
(n = 57)
Trend
Intended
tradition
popsize
edu
youth




Phase 1
(n = 166)
Trend
Intended
tradition
popsize
edu
youth

Phase 2
(n = 59)
Trend
Intended
tradition
popsize
edu
youth



Phase 1
(n = 110)
Trend
Intended
tradition
popsize
edu
youth

Phase 2
(n = 261)
Trend
Intended
tradition
popsize
edu
youth



Phase 1


(n = 82)

Trend
 Intended
tradition
dialect
 accom
 popsize
 edu
youth

Phase 2

(n = 44)

Trend
 Intended
 tradition
 dialect
 accom
popsize
 edu
youth



Phase 1


(n = 107)

Trend
 Intended
tradition
dialect
 accom
 popsize
 edu
youth

Phase 2

(n = 35)

Trend
 Intended
 tradition
 dialect
 accom
popsize
 edu
 youth



Phase 1


(n = 59)

Trend
 Intended
 tradition
 dialect
 accom
 popsize
 edu
 youth

Phase 2

(n = 161)

Trend
 Intended
 tradition
 dialect
 accom
popsize
 edu
 youth



Phase 1

(n = 77)

Trend
 Intended
tradition
 dialect
 accom
 popsize
 edu
youth

Phase 2


(n = 28)

Trend
 Intended
 tradition
 dialect
 accom
 popsize
 edu
 youth

Phase 3

(n = 45)

Trend
 Intended
 tradition
 dialect
 accom
popsize
 edu
youth



Phase 1

(n = 49)

Trend
 Intended
 tradition
 dialect
 accom
 popsize
 edu
 youth

Phase 2

(n = 128)

Trend
 Intended
 tradition
dialect
 accom
popsize
 edu
 youth

A basic overview

- Significant factors across all phases
 - Top (no dialect info), bottom (with dialect info)





Study conclusions



- Main hypothesis (late 19c Estonian):
 - Spontaneous changes align with an influx of new authors
 - Prescriptive events line up clearly with trends
 - Some generational influence apparent: successful changes are led by young and large cities.
- Study generally:
 - Data is everywhere and has not been collected
 - Already „first look“ at it can give insights
 - Thinking in terms of data also adds to theory



General discussion



- 80% of DH research is finding the data and getting it ready
 - Manual + technological work
 - Good-enough solutions for current tasks
- Open collections can have a variety of uses
 - Difficult to predict
- Also by-products of research can be useful
 - Databases & processing
 - Visualizations & understanding



Some advice/thoughts

- Start & stay open, document everything!
- Think how your current work fits to the whole project
 - Work with manageable chunks and fit them in right away
- Don't worry about lack of skills beforehand, but consult specialists!
 - Usually your problems are not new and have solutions.
 - However working with „data“ is new to humanities so you may need to step outside your institute/department.



Interactive plot links

- https://peetertinits.github.io/slides/DH-labs-2019/presentation/DH-lab_2019.html#14
- https://peetertinits.github.io/slides/EDHC2018/presentation/EDHC_2018.html#45
- https://peetertinits.github.io/slides/EDHC2018/presentation/EDHC_2018.html#50
- <https://peetertinits.github.io/slides/plots/authorbirths.html>
- <https://peetertinits.github.io/slides/plots/samamaakond.html>